

Sistem Identifikasi dan Analisis Gangguan Tidur Berbasis Machine Learning

Disusun untuk memenuhi Tugas Mata Kuliah Pemelajaran Mesin



Penyusun:

Nama :Edi Prayitno

NBI :1462400011

Dosen pengampu:Mahmud Suyuti,S.Kom.,M.Kom

PROGRAM STUDI TEKNIK INFORMATIKA

**FAKULTAS TEKNOLOGI ELEKTRO DAN INFORMATIKA
CERDAS**

UNIVERSITAS 17 AGUSTUS 1945 SURABAYA

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Kualitas tidur merupakan salah satu faktor krusial yang menentukan tingkat produktivitas serta kesehatan fisik dan mental seseorang. Gangguan tidur yang tidak tertangani, seperti durasi tidur yang pendek atau fragmentasi tidur, secara signifikan dapat meningkatkan risiko penyakit kardiovaskular, gangguan metabolisme, hingga penurunan fungsi kognitif (Medic et al., 2017). Di era modern yang serba cepat, prevalensi gangguan tidur seperti *Insomnia* dan *Sleep Apnea* terus meningkat. Berdasarkan penelitian yang dipublikasikan dalam *Journal of Family Medicine and Primary Care*, diperkirakan sekitar 33% populasi orang dewasa mengalami gejala insomnia (Bhaskar et al., 2016), yang sering kali tidak disadari oleh penderitanya hingga menimbulkan dampak kesehatan yang lebih serius. Kurangnya pemahaman serta keterbatasan akses untuk melakukan skrining klinis membuat banyak individu mengabaikan pola tidur mereka.

Seiring dengan perkembangan teknologi kecerdasan artifisial, metode pembelajaran mesin (*machine learning*) menawarkan solusi inovatif untuk memetakan dan menganalisis pola kebiasaan manusia yang kompleks menjadi wawasan yang bermakna (Bishop, 2006). Proyek ini bertujuan untuk merancang sebuah solusi perangkat lunak berbasis data guna menyelesaikan permasalahan identifikasi gangguan tidur. Sistem ini mengintegrasikan pendekatan *Supervised Learning* menggunakan algoritma *K-Nearest Neighbors* (KNN) untuk mengklasifikasikan jenis gangguan tidur berdasarkan metrik kesehatan pengguna. Selain itu, sistem ini menggunakan pendekatan *Reinforcement Learning* untuk memberikan rekomendasi evaluasi tingkat stres secara adaptif. Solusi ini diharapkan dapat menjadi alat skrining awal yang interaktif dan mudah diakses oleh masyarakat melalui antarmuka web.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam proyek ini adalah:

1. Bagaimana merancang dan mengimplementasikan model *Supervised Learning* (KNN) dan *Reinforcement Learning* (Q-Learning) untuk menganalisis data metrik kesehatan tidur pengguna?

2. Bagaimana mengevaluasi kinerja model yang dikembangkan menggunakan metrik yang relevan (seperti akurasi) agar layak digunakan?
3. Bagaimana menginterpretasikan hasil prediksi model serta mengidentifikasi potensi bias dan aspek etika terkait privasi data pengguna?
4. Bagaimana melakukan *deployment* model ke dalam sebuah aplikasi web interaktif agar hasil prediksi dapat dengan mudah digunakan sebagai alat skrining awal?

1.3 Tujuan Proyek

Tujuan utama dari pengembangan sistem ini adalah:

1. Membangun dan mengimplementasikan model pembelajaran mesin terintegrasi (KNN dan Q-Learning) untuk mendeteksi dan mengevaluasi potensi gangguan tidur pengguna.
2. Mengukur dan mengevaluasi kinerja model klasifikasi untuk memastikan validitas hasil prediksi.
3. Menyusun refleksi etis terkait transparansi, bias data, dan perlindungan data pengguna dalam implementasi sistem kecerdasan artifisial.
4. Mengembangkan prototipe aplikasi web sederhana (berbasis Streamlit) yang siap mendemonstrasikan fungsi model secara interaktif kepada pengguna akhir.

BAB 2

METODOLOGI DAN PRAPEMROSESAN DATA

2.1 Deskripsi Dataset

Proyek ini menggunakan dataset *Sleep Health and Lifestyle* yang memuat berbagai metrik kesehatan dan kebiasaan sehari-hari pengguna. Dataset ini mencakup variabel numerik dan kategorikal, seperti durasi tidur, tingkat stres, serta kategori gangguan tidur (*Sleep Disorder*) yang menjadi variabel target dalam penyelesaian masalah klasifikasi ini. Pemilihan dataset ini didasarkan pada relevansinya terhadap rumusan masalah untuk mengidentifikasi pola kebiasaan yang berujung pada potensi gangguan tidur.

Dataset ini terdiri dari 374 baris data dan memiliki 12 kolom fitur (setelah proses pembersihan) yang merepresentasikan berbagai atribut fisik dan kebiasaan pengguna.

2.2 Tahapan Prapemrosesan Data (Data Preprocessing)

Sebelum data digunakan untuk melatih model pembelajaran mesin, diperlukan serangkaian tahapan prapemrosesan untuk memastikan kualitas dan format data sesuai dengan algoritma yang digunakan. Tahapan yang dilakukan meliputi:

1. **Pembersihan Data (*Data Cleaning*):** Menghapus atribut yang tidak memiliki nilai prediktif atau tidak relevan dengan analisis pola tidur. Pada tahap ini, atribut seperti Person ID dihapus dari dataset karena hanya berfungsi sebagai pengenalan unik dan dapat memicu *noise* pada proses *training* model.
2. **Transformasi Data (*Label Encoding*):** Algoritma *machine learning*, khususnya *K-Nearest Neighbors* (KNN) dan *Q-Learning*, membutuhkan data masukan berupa angka (numerik). Oleh karena itu, seluruh variabel berskala kategorikal (teks) ditransformasikan menjadi representasi numerik menggunakan fungsi *LabelEncoder*.
3. **Standarisasi Skala (*Feature Scaling*):** Mengingat algoritma KNN sangat sensitif terhadap rentang skala antar fitur karena bekerja berdasarkan perhitungan jarak (*Euclidean distance*), dilakukan proses standarisasi menggunakan *StandardScaler*. Proses ini memastikan semua fitur prediktor memiliki rata-rata nol dan variansi satu, sehingga tidak ada fitur dominan yang bias karena memiliki skala angka yang lebih besar.

Person ID	Gender	Age	Occupation	Sleep Duration	Quality of Sleep	Physical Activity Level	Stress Level	BMI Category	Blood Pressure	Heart Rate	Daily Steps	Sleep Disorder
1	Male	27	Software Engineer	6,1	6	42	6	Overweight	126/83	77	4200	None
2	Male	28	Doctor	6,2	6	60	8	Normal	125/80	75	10000	None
3	Male	28	Doctor	6,2	6	60	8	Normal	125/80	75	10000	None
4	Male	28	Sales Representative	5,9	4	30	8	Obese	140/90	85	3000	Sleep Apnea
5	Male	28	Sales Representative	5,9	4	30	8	Obese	140/90	85	3000	Sleep Apnea
6	Male	28	Software Engineer	5,9	4	30	8	Obese	140/90	85	3000	Insomnia
7	Male	29	Teacher	6,3	6	40	7	Obese	140/90	82	3500	Insomnia
8	Male	29	Doctor	7,8	7	75	6	Normal	120/80	70	8000	None
9	Male	29	Doctor	7,8	7	75	6	Normal	120/80	70	8000	None
10	Male	29	Doctor	7,8	7	75	6	Normal	120/80	70	8000	None
11	Male	29	Doctor	6,1	6	30	8	Normal	120/80	70	8000	None
12	Male	29	Doctor	7,8	7	75	6	Normal	120/80	70	8000	None
13	Male	29	Doctor	6,1	6	30	8	Normal	120/80	70	8000	None
14	Male	29	Doctor	6	6	30	8	Normal	120/80	70	8000	None
15	Male	29	Doctor	6	6	30	8	Normal	120/80	70	8000	None
16	Male	29	Doctor	6	6	30	8	Normal	120/80	70	8000	None
17	Female	29	Nurse	6,5	5	40	7	Normal Weight	132/87	80	4000	Sleep Apnea
18	Male	29	Doctor	6	6	30	8	Normal	120/80	70	8000	Sleep Apnea
19	Female	29	Nurse	6,5	5	40	7	Normal Weight	132/87	80	4000	Insomnia
20	Male	30	Doctor	7,6	7	75	6	Normal	120/80	70	8000	None
21	Male	30	Doctor	7,7	7	75	6	Normal	120/80	70	8000	None
22	Male	30	Doctor	7,7	7	75	6	Normal	120/80	70	8000	None
23	Male	30	Doctor	7,7	7	75	6	Normal	120/80	70	8000	None
24	Male	30	Doctor	7,7	7	75	6	Normal	120/80	70	8000	None
25	Male	30	Doctor	7,8	7	75	6	Normal	120/80	70	8000	None
26	Male	30	Doctor	7,9	7	75	6	Normal	120/80	70	8000	None
27	Male	30	Doctor	7,8	7	75	6	Normal	120/80	70	8000	None
28	Male	30	Doctor	7,9	7	75	6	Normal	120/80	70	8000	None

Gambar2.1dataset sebelum Scaling

```

*** === PREPROCESSING UNTUK RL SELESAI ===
Bentuk data sekarang (Baris, Kolom Fitur): (374, 12)

Cuplikan 3 baris pertama data_rl untuk RL:
  Gender  Age  Occupation  Sleep Duration  Quality of Sleep  \
0        1   27           9             61             6
1        1   28           1             62             6
2        1   28           1             62             6

  Physical Activity Level  Stress Level  BMI  Category  Blood Pressure  \
0                42             6        3           11
1                60             8        0            9
2                60             8        0            9

  Heart Rate  Daily Steps  Sleep Disorder
0         77       4200             2
1         75      10000             2
2         75      10000             2

```

Gambar 2.2: Output proses prapemrosesan data yang menunjukkan dataset telah berhasil ditransformasikan menjadi representasi numerik dengan dimensi 374 baris dan 12 kolom fitur.

Berdasarkan hasil tersebut, seluruh variabel kategorikal telah berhasil di-encode menjadi nilai numerik, sehingga data siap digunakan sebagai input bagi model *Reinforcement Learning* maupun klasifikasi KNN tanpa kendala tipe data.

2.3 Persiapan Data untuk Environment Reinforcement Learning

Secara spesifik untuk kebutuhan *Reinforcement Learning*, dataset yang telah melalui proses transformasi nilai kategorik diubah formatnya menjadi *Numpy Array*. Hal ini dilakukan untuk memenuhi struktur matriks status (*state*) yang diwajibkan oleh parameter lingkungan (*environment*) penjadwalan cerdas, sehingga agen Q-Learning dapat melakukan simulasi iterasi berdasarkan tingkat stres (*Stress Level*) pengguna secara optimal.

BAB 3

IMPLEMENTASI MODEL

3.1 Pendekatan *Supervised Learning* (KNN)

Pada proyek ini, algoritma *K-Nearest Neighbors* (KNN) digunakan untuk mengklasifikasikan jenis gangguan tidur pengguna. KNN dipilih karena kemampuannya dalam mengenali pola data tanpa memerlukan asumsi distribusi data yang kompleks. Sistem bekerja dengan menghitung jarak terdekat (*Euclidean distance*) antara data input pengguna baru dengan data latih yang sudah ada dalam dataset. Berdasarkan jumlah tetangga terdekat (\$k\$) yang ditentukan, sistem akan memberikan label prediksi gangguan tidur yang paling dominan muncul.

```
[67]
✓ 0s
# KNN
knn = KNeighborsClassifier(n_neighbors=5)
knn.fit(X_train, y_train)
y_pred_knn = knn.predict(X_test)

# Decision Tree
dt = DecisionTreeClassifier(random_state=42)
dt.fit(X_train, y_train)
y_pred_dt = dt.predict(X_test)

# Random Forest
rf = RandomForestClassifier(n_estimators=100, random_state=42)
rf.fit(X_train, y_train)
y_pred_rf = rf.predict(X_test)
```

Gambar 3.1: Proses pelatihan model *K-Nearest Neighbors* (KNN) dengan menggunakan data latih X_{train} dan y_{train}

Pada tahap ini, model KNN diinisialisasi dan dilatih menggunakan dataset yang telah diproses sebelumnya. Penggunaan metode `.fit()` bertujuan agar model dapat mempelajari pola hubungan antara variabel input (fitur) dan label target (kondisi insomnia) dari data latih, sehingga model siap untuk melakukan prediksi pada data yang belum pernah dilihat sebelumnya.

```
KNN Results:
Accuracy: 0.8938053097345132
Precision: 0.8842906678727575
Recall: 0.8526483472720031
F1 Score: 0.8651320993513685

Decision Tree Results:
Accuracy: 0.8495575221238938
Precision: 0.8241521918941275
Recall: 0.8257666268418956
F1 Score: 0.8241521918941275

Random Forest Results:
Accuracy: 0.8938053097345132
Precision: 0.8842906678727575
Recall: 0.8526483472720031
F1 Score: 0.8651320993513685
```

Gambar 3.2: Hasil evaluasi performa model menggunakan fungsi `evaluate_model`

Gambar di atas menunjukkan hasil perbandingan evaluasi antara model *K-Nearest Neighbors* (KNN), *Decision Tree*, dan *Random Forest*. Berdasarkan data yang ditampilkan, model KNN dan *Random Forest* menunjukkan performa yang identik dengan tingkat akurasi sebesar 89,38%, *precision* 88,43%, *recall* 85,26%, dan *F1-Score* 86,51%. Sementara itu, model *Decision Tree* memiliki performa yang sedikit lebih rendah dengan akurasi 84,96%. Hasil ini mengindikasikan bahwa model KNN dan *Random Forest* lebih efektif dalam mengklasifikasikan data dibandingkan dengan *Decision Tree* pada dataset yang digunakan.

3.2 Arsitektur Neural Network (MLP)

Selain pendekatan berbasis tetangga terdekat, sistem juga diimplementasikan menggunakan arsitektur *Neural Network* atau *Multi-Layer Perceptron* (MLP) untuk meningkatkan akurasi klasifikasi multi-kelas pada target gangguan tidur. Arsitektur model yang disusun terdiri dari tiga lapisan utama:

- **Lapisan Input:** Menerima jumlah fitur yang disesuaikan secara dinamis dari dimensi dataset input.
- **Lapisan Tersembunyi (*Hidden Layers*):** Terdiri dari dua lapis *Dense* (16 dan 8 neuron) dengan fungsi aktivasi *ReLU* untuk mengekstraksi fitur kompleks dari data kesehatan pengguna.
- **Lapisan Output:** Memiliki 3 neuron yang merepresentasikan klasifikasi gangguan tidur dengan fungsi aktivasi *Softmax* untuk menghasilkan distribusi probabilitas kelas.

Model dikompilasi dengan *optimizer Adam* dan *loss function sparse_categorical_crossentropy*, yang terbukti efektif untuk permasalahan klasifikasi dengan banyak kategori

```
import tensorflow as tf
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

# Menentukan jumlah kolom dari X_train secara otomatis
jumlah_fitur = X_train.shape[1]

print("Membangun model Neural Network (MLP) Multi-Class...")
model = Sequential([
    Dense(16, activation='relu', input_shape=(jumlah_fitur,)), # Input & Hidden Layer 1
    Dense(8, activation='relu'), # Hidden Layer 2
    Dense(3, activation='softmax') # Output Layer 3 neuron karena ada 3 kelas, aktivasi 'softmax'
])

# Penggunaan 'sparse_categorical_crossentropy' karena klasifikasi multi-kelas
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

# Menampilkan ringkasan arsitektur model
model.summary()

# --- PROSES PELATIHAN MODEL (BACKPROPAGATION) ---
print("Memulai pelatihan model...")
# Menyimpan history untuk plotting grafik nanti
history = model.fit(X_train, y_train,
                    epochs=50,
                    batch_size=10,
                    validation_data=(X_test, y_test),
                    verbose=1)

--- Membangun model Neural Network (MLP) Multi-Class...
/usr/local/lib/python3.12/dist-packages/keras/src/layers/core/dense.py:106: UserWarning: Do not pass an 'input_shape'/'input_dim' argument to a layer. When using Sequential models, prefer using an 'Input(shape)' object as the first layer in the model instead.
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)
Model: "sequential_5"

Layer (type)                 Output Shape              Param #
-----
dense_15 (Dense)             (None, 16)                160
dense_16 (Dense)             (None, 8)                 144
dense_17 (Dense)             (None, 3)                 27
Total params: 331 (1.39 KB)
Trainable params: 331 (1.39 KB)
Non-trainable params: 0 (0.00 KB)
```

Gambar 3.3: Arsitektur Neural Network dan Ringkasan Parameter Model.

3.3 Pendekatan Reinforcement Learning (Q-Learning)

Selain klasifikasi, sistem ini mengimplementasikan *Reinforcement Learning* (RL) untuk memberikan rekomendasi evaluasi tingkat stres secara adaptif. Agen RL belajar melalui proses *trial-and-error* di dalam *environment* yang telah didefinisikan. Agen diberikan *reward* (imbalan) positif jika memberikan rekomendasi jam tidur yang sesuai dan *reward* negatif jika tidak sesuai. Melalui iterasi berulang, agen akan memperbarui *Q-Table* untuk menentukan aksi optimal dalam berbagai status tingkat stres pengguna.

3.4 Deployment Aplikasi dengan Streamlit

Untuk mempermudah interaksi pengguna, model yang telah dilatih dideploy ke dalam aplikasi web menggunakan *framework* Streamlit. Aplikasi ini memungkinkan pengguna memasukkan data kesehatan seperti durasi tidur, aktivitas fisik, dan tingkat stres secara real-time. Setelah data diinput, sistem akan memproses data tersebut melalui model KNN untuk memberikan diagnosis awal mengenai gangguan tidur, serta memberikan saran jadwal tidur berbasis logika *Reinforcement Learning* yang telah dipelajari sebelumnya

BAB 4

HASIL DAN PEMBAHASAN

4.1 Hasil Implementasi Model

Dalam tahap ini, dilakukan pengujian terhadap tiga model klasifikasi untuk menentukan tingkat akurasi dalam mendeteksi gejala insomnia. Model yang diuji meliputi *K-Nearest Neighbors* (KNN), *Decision Tree*, dan *Random Forest*. Hasil evaluasi yang diperoleh dari image_8f72d3.png menunjukkan bahwa model KNN dan *Random Forest* memiliki performa yang identik dan lebih unggul dibandingkan dengan model *Decision Tree*.

Berikut adalah ringkasan hasil evaluasi ketiga model tersebut:

- **Akurasi:** KNN dan *Random Forest* mencapai 89.38%, sedangkan *Decision Tree* sebesar 84.96%.
- **Precision:** KNN dan *Random Forest* mencapai 88.43%, sedangkan *Decision Tree* sebesar 82.42%.
- **Recall:** KNN dan *Random Forest* mencapai 85.26%, sedangkan *Decision Tree* sebesar 82.58%.
- **F1-Score:** KNN dan *Random Forest* mencapai 86.51%, sedangkan *Decision Tree* sebesar 82.42%.

4.2 Pembahasan

Berdasarkan hasil pengujian di atas, penggunaan model *K-Nearest Neighbors* (KNN) dan *Random Forest* memberikan hasil klasifikasi yang paling optimal untuk dataset yang digunakan dengan tingkat akurasi mencapai 89,38%. Performa *Decision Tree* yang sedikit lebih rendah (84,96%) kemungkinan disebabkan oleh sifat dasar model tersebut yang rentan terhadap *overfitting* pada dataset tertentu, dibandingkan dengan model *ensemble* seperti *Random Forest* atau algoritma berbasis jarak seperti KNN yang lebih stabil dalam menangani variasi data.

Dalam tugas akhir ini, **dipilih metode *K-Nearest Neighbors* (KNN) sebagai model akhir.** Metode ini dipilih karena kemampuannya dalam melakukan klasifikasi berdasarkan kemiripan pola perilaku antar data secara intuitif. Sebagai algoritma yang bersifat *instance-*

based learning, KNN sangat efektif dalam menangani dataset yang memiliki keterkaitan lokal yang kuat antar fitur, sehingga mampu menghasilkan akurasi yang optimal (89,38%) dengan logika yang sederhana namun transparan dalam proses pengambilan keputusannya. Hal ini menjadikan KNN sebagai model yang paling sesuai dan efisien untuk diimplementasikan dalam sistem deteksi dini insomnia yang dikembangkan.

4.3 Refleksi Etis dan Privasi Data

Dalam pengembangan sistem ini, aspek etika dan privasi data menjadi perhatian utama untuk menjamin kepercayaan pengguna. Mengingat sistem ini menangani informasi kesehatan yang bersifat sensitif, implementasi pada aplikasi web telah dirancang untuk meminimalisir risiko kebocoran data dengan tidak menyimpan informasi kesehatan pengguna secara permanen di server (*stateless*), melainkan hanya memprosesnya saat sesi penggunaan berlangsung. Selain itu, potensi bias data telah diantisipasi dengan melakukan proses pembersihan data yang ketat (seperti menghapus atribut pengenalan unik) guna memastikan bahwa model tidak mempelajari pola yang diskriminatif. Transparansi penggunaan algoritma juga dikedepankan dengan memberikan penjelasan yang jelas kepada pengguna mengenai bagaimana data mereka diolah untuk menghasilkan prediksi, sehingga hak pengguna atas informasi pribadinya tetap terjaga dan terlindungi selama proses skrining awal berlangsung.

BAB 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan pengujian sistem deteksi dini gangguan tidur yang telah dilakukan, dapat ditarik kesimpulan sebagai berikut:

1. Model *K-Nearest Neighbors* (KNN) berhasil diimplementasikan dengan tingkat akurasi sebesar 89,38% dalam mengklasifikasikan jenis gangguan tidur. Performa ini membuktikan bahwa metode KNN sangat efektif dalam mengenali pola data kesehatan berdasarkan kedekatan fitur-fitur klinis pengguna.
2. Penggunaan pendekatan *Reinforcement Learning* (Q-Learning) berhasil diintegrasikan ke dalam sistem untuk memberikan rekomendasi evaluasi tingkat stres secara adaptif, sehingga sistem tidak hanya mendeteksi gangguan tetapi juga menawarkan solusi penjadwalan yang interaktif.
3. Pengembangan aplikasi berbasis web menggunakan *framework* Streamlit telah berhasil dilakukan, memungkinkan pengguna untuk melakukan skrining awal secara mandiri dengan antarmuka yang intuitif dan mudah diakses.
4. Seluruh tahapan mulai dari prapemrosesan hingga *deployment* telah dilakukan dengan memperhatikan prinsip transparansi data, di mana seluruh fitur yang tidak relevan telah dibersihkan untuk menghindari *noise* dan bias pada model.

5.2 Saran

Untuk pengembangan sistem deteksi dini gangguan tidur di masa yang akan datang, penulis memberikan beberapa saran sebagai berikut:

1. **Penambahan Dataset:** Mengingat akurasi model sangat bergantung pada kualitas data, disarankan untuk menambah jumlah sampel dataset agar mencakup variasi usia, kondisi kesehatan, dan demografi yang lebih luas sehingga model memiliki kemampuan generalisasi yang lebih baik.
2. **Optimasi Hyperparameter:** Pada model KNN, pengembangan selanjutnya dapat melibatkan teknik *Hyperparameter Tuning* (seperti *Grid Search*) untuk menentukan

nilai \$\$\$ yang paling optimal secara otomatis, guna meningkatkan akurasi melampaui hasil yang dicapai saat ini.

3. **Integrasi Perangkat Wearable:** Mengembangkan sistem agar dapat terintegrasi dengan data sensor dari perangkat *wearable* (seperti *smartwatch*) secara *real-time*, sehingga deteksi gangguan tidur dapat dilakukan berdasarkan data fisik yang lebih akurat daripada sekadar input manual pengguna.
4. **Penguatan Aspek Etika dan Privasi:** Menambahkan fitur enkripsi data pengguna pada aplikasi web untuk memastikan perlindungan informasi kesehatan pribadi yang lebih ketat sesuai dengan standar privasi data yang berlaku.

LAMPIRAN

A. Tautan Kode Sumber (*Source Code*)

Seluruh implementasi kode sumber yang digunakan dalam proyek ini, meliputi *notebook* pemrosesan data, pelatihan model pembelajaran mesin, serta skrip aplikasi berbasis Streamlit, dapat diakses dan ditinjau melalui tautan berikut:

https://colab.research.google.com/drive/1Kg2dslMHfV0MYDQv7cEnX6s2Ylh0m_VW?usp=sharing

DAFTAR PUSTAKA

Abadi, M., et al. (2015). *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems*.

Bhaskar, S., Hemavathy, D., & Prasad, S. (2016). Prevalence of chronic insomnia in adult patients and its correlation with medical comorbidities. *Journal of Family Medicine and Primary Care*, 5(4), 780–784.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Kaggle. (2023). *Sleep Health and Lifestyle Dataset*. Diakses dari Kaggle.

Medic, G., Wille, M., & Hemels, M. E. (2017). Short- and long-term health consequences of sleep disruption. *Nature and Science of Sleep*, 9, 151–161.

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction*. MIT Press.

Vettigli, G. (2018). *MiniSom: Minimalistic and NumPy-based implementation of the Self Organizing Map*. Diakses dari <https://github.com/JustGlowing/minisom>.